

Proyecto 2

Álgebra Lineal Avanzada y Modelamiento – IMT2230

1.- Introducción

En este proyecto se aplica el algoritmo PageRank a una red real de tráfico aéreo de Estados Unidos, obtenida desde el repositorio KONECT (`maayan-faa`). El objetivo es construir la Matriz de Google a partir de la matriz de hipervínculos de la red, calcular el vector de PageRank mediante iteración de potencias, e interpretar los resultados en el contexto del sistema de rutas preferentes de la FAA.

La idea principal consiste en modelar una marcha aleatoria sobre la red, donde un agente sigue rutas reales con probabilidad α y salta a un nodo al azar con probabilidad $1 - \alpha$. El PageRank de cada nodo corresponde a la fracción de tiempo que esta marcha pasa en él a largo plazo.

2.- Red elegida y descripción

Se eligió la red `maayan-faa` de KONECT, construida a partir de la base de datos de Rutas Preferentes (*Preferred Routes Database*) del *National Flight Data Center* de la FAA. Los nodos representan aeropuertos o centros de servicio, y las aristas dirigidas representan una ruta preferente recomendada entre dos nodos ($j \rightarrow i$).

Se eligió esta red porque tiene un contexto real e interpretable, cumple los requisitos de tamaño del proyecto, y permite formular una pregunta concreta sobre centralidad dentro de un sistema de transporte real.

Estadística	Valor
Número de nodos (n)	1 226
Número de aristas (m)	2 615
Grado de entrada medio	2.133
Grado de salida medio	2.133
Nodo de mayor grado de entrada	312 (in-degree = 20)
Densidad ($m/(n(n-1))$)	0.001741
Nodos colgantes	143 (11.66 % del total)

Cuadro 1: Estadísticas básicas de la red.

La densidad es muy baja, lo que es esperable en una red de infraestructura real. Un 11.66 % de los nodos son colgantes (sin aristas de salida), lo que se retoma más adelante al construir la matriz S .

3.- Pregunta e hipótesis inicial

Pregunta: ¿Qué aeropuertos o centros de servicio son los más centrales dentro de la red de rutas preferentes de la FAA?

Hipótesis inicial: se esperaba que los nodos con mayor grado de entrada (como el nodo 312, con 20 rutas entrantes) tuvieran también un PageRank alto. También se anticipó que podrían existir nodos con posición estratégica en la red, enlazados por otros nodos importantes, cuyo PageRank

fuera más alto de lo que sugiere su grado de entrada. Además, se esperaba que los nodos colgantes no distorsionaran fuertemente el resultado, gracias a la corrección de la matriz S .

4.- Análisis exploratorio de la red

La Figura 1 muestra la distribución del grado de entrada y de salida. Ambas tienen forma de cola larga, la mayoría de los nodos tiene grado bajo (1 a 3), y muy pocos concentran grados altos (hasta 20 en entrada y 25 en salida), lo cual es típico de redes de infraestructura real.




Figura 1: Distribución del grado de entrada y de salida.

Se identificaron 143 nodos colgantes (11.66 %). Estos nodos son problemáticos para PageRank porque su columna en H queda en cero, rompiendo la propiedad de columna-estocástica. Este problema se resuelve más adelante con la matriz S , reemplazando esas columnas por el vector uniforme $\mathbf{1}/n$.

La tabla 2 muestra los 10 nodos de mayor grado de entrada y de salida. El nodo 312 encabeza ambos rankings, funcionando como un hub bidireccional. El dataset no incluye nombres de aeropuertos, solo IDs numéricos.

Nodo	in-degree	Nodo	out-degree
312	20	68	24
68	13	52	22
82	13	44	20
110	13	113	20
109	12	89	18
52	11	187	18
105	11	47	17
135	11	312	17
10	10	604	17
34	10	212	15

Cuadro 2: Top 10 nodos por grado de entrada y de salida.

Finalmente, la red **no** es fuertemente conexa, tiene 434 componentes fuertemente conexas, y la más grande cubre solo 792 de los 1 226 nodos ($\approx 65\%$). Esto no afecta a PageRank porque la Matriz de Google G es siempre irreducible y aperiódica, independientemente de la estructura del grafo subyacente.

5.- Construcción de la Matriz de Google

Se construyó la matriz de hipervínculos $H \in \mathbb{R}^{n \times n}$, con

$$H_{ij} = \frac{1}{\text{out}(j)} \text{ si } j \rightarrow i, \quad H_{ij} = 0 \text{ si no.}$$

Se verificó que exactamente 143 columnas de H son cero, coincidiendo con los nodos colgantes.

Luego se construyó la matriz columna-estocástica

$$S = H + \frac{1}{n} \mathbf{1} \mathbf{a}^T,$$

donde $a_j = 1$ si el nodo j es colgante. Se verificó que todas las columnas de S suman exactamente 1.

Finalmente se construyó la Matriz de Google

$$G = \alpha S + \frac{1 - \alpha}{n} \mathbf{1} \mathbf{1}^T, \quad \alpha = 0,85,$$

el valor clásico usado por Google. Se verificó que todas las entradas de G son estrictamente positivas y que sus columnas suman 1, lo que garantiza que G es irreducible y aperiódica sin importar que el grafo original no sea fuertemente conexo.

6.- Cálculo de PageRank mediante iteración de potencias

Se implementó la iteración $\mathbf{r}^{(k+1)} = G\mathbf{r}^{(k)}$, partiendo de $\mathbf{r}^{(0)} = \mathbf{1}/n$, hasta que $\|\mathbf{r}^{(k+1)} - \mathbf{r}^{(k)}\|_1 < 10^{-10}$. La iteración convergió en 52 pasos, con $\|\mathbf{r}^*\|_1 = 1$ y todos los valores estrictamente positivos, tal como predice la teoría (Figura 2).




Figura 2: Curva de convergencia de la iteración de potencias.

El decaimiento del error es geométrico, con una razón empírica de $\approx 0,68$, más rápida que la cota teórica $\alpha = 0,85$. Esto es consistente con la teoría, α acota el peor caso, mientras que la brecha espectral real de esta red permite converger algo más rápido.

La Tabla 3 muestra los 20 nodos con mayor PageRank. El nodo 312 encabeza el ranking, consistente con la hipótesis inicial. Sin embargo, ya se observan casos que la contradicen parcialmente, el nodo 19 (in-degree 7, colgante) queda en el puesto #4, y el nodo 842 (in-degree 1) aparece en el puesto #5.

Rango	Nodo	PageRank	in-degree	out-degree
1	312	0.007708	20	17
2	61	0.005693	8	0
3	105	0.005344	11	1
4	19	0.005165	7	0
5	842	0.004756	1	1
6	187	0.004476	9	18
7	578	0.004384	2	2
8	86	0.004263	10	2
9	52	0.003951	11	22
10	311	0.003874	8	4
11	38	0.003788	8	0
12	26	0.003765	9	0
13	68	0.003553	13	24
14	201	0.003347	7	7
15	306	0.003334	5	9
16	109	0.003312	12	10
17	44	0.003002	8	20
18	157	0.002941	9	12
19	89	0.002907	8	18
20	266	0.002881	7	6

Cuadro 3: Top 20 nodos por PageRank.

7.- PageRank vs. grado de entrada

Se calculó la correlación de Pearson entre grado de entrada y PageRank, obteniendo $r = 0,797$ ($p < 10^{-269}$), una relación fuerte, pero no perfecta (Figura 3).




Figura 3: PageRank vs. grado de entrada. En rojo, los 10 nodos de mayor PageRank.

Filtrando los nodos con in-degree genuinamente alto (percentil 90, in-degree ≥ 4), se encontraron

nodos como el 220, 470 y 92 con in-degree = 4 pero PageRank bajo (posiciones 490 a 660 de 1 226):
 sus pocos enlaces entrantes provienen de nodos poco relevantes.

El caso más claro en la dirección opuesta es el nodo 842: in-degree = 1, pero puesto #5 de PageRank. Su único predecesor es el **nodo 105** (in-degree 11, PageRank 0.00534, dentro del top-10). El nodo 842 hereda importancia del nodo 105: PageRank no depende solo de cuántos enlaces entrantes tiene un nodo, sino de qué tan importantes son quienes lo enlazan.

8.- Interpretación de resultados

Los nodos de mayor PageRank (312, 61, 105, 19, 842, ...) tienen sentido como nodos influyentes, combinan buen grado de entrada y/o salida, o están enlazados por otros nodos relevantes (como el caso de 842 y 105). El dataset no incluye nombres de aeropuertos, por lo que la interpretación queda a nivel estructural.

La Figura 4 muestra el subgrafo inducido por los 40 nodos de mayor PageRank, con el tamaño de cada nodo proporcional a su PageRank.




Figura 4: Subgrafo de los 40 nodos con mayor PageRank.

El subgrafo no forma un solo bloque conectado, sino varios grupos pequeños, además de nodos que aparecen aislados dentro de este subconjunto. Estos últimos sí tienen conexiones en la red completa, pero con nodos fuera del top-40, su PageRank alto proviene de vínculos externos al grupo de mayor importancia. Esto es consistente con la fragmentación en 434 componentes observada en la Sección 4. El dataset no incluye atributos de nodo, por lo que no fue posible colorear el subgrafo por categoría.

9.- Discusión, limitaciones y conclusiones

La pregunta planteada quedó respondida, el nodo 312 es el más central de la red, combinando buen grado de entrada y salida. Sin embargo, el nodo 842 mostró que PageRank también puede capturar importancia heredada que el grado de entrada no refleja.

La hipótesis inicial se cumplió parcialmente. La correlación de 0,797 confirma la relación esperada entre in-degree y PageRank, pero el caso del nodo 842 (enlazado únicamente por el nodo 105, que sí es relevante) valida también la segunda parte de la hipótesis, sobre posición estratégica más allá del grado de entrada.

Entre las limitaciones, un 11.66 % de nodos colgantes es una fracción considerable, y sin la corrección de S el modelo se rompería. La red tampoco es fuertemente conexa, por lo que un modelo de marcha aleatoria sin el término de teletransporte de G no sería válido. Además, la red es muy dispersa, y el dataset no incluye metadata de los nodos (nombre, región, tipo de aeropuerto), lo que limita la interpretación cualitativa; un trabajo futuro podría cruzar los IDs con una base de datos de aeropuertos de la FAA.

Del análisis surgieron preguntas nuevas, como qué caracteriza a los subsistemas regionales observados en el subgrafo de mayor PageRank, y por qué existe una fracción tan alta de nodos colgantes en este dataset.

En términos simples, imaginando un avión fantasma que vuela sin parar siguiendo rutas reales, saltando ocasionalmente a un aeropuerto al azar, los aeropuertos más importantes son los que ese avión visita más seguido a largo plazo, y no necesariamente los que reciben más vuelos directos, sino los que están bien conectados con otros aeropuertos que también son importantes.

10.- Reproducibilidad

El análisis fue realizado en Python usando principalmente `networkx`, `numpy`, `scipy`, `pandas` y `matplotlib`. El proyecto fue desarrollado en un notebook de Google Colab.

Para reproducir el análisis se debe contar con el archivo `out.maayan-faa`, descargado desde KONECT (<http://konect.cc/networks/maayan-faa/>). El notebook busca este archivo y luego ejecuta todo el proceso de construcción de la Matriz de Google, cálculo de PageRank y generación de las figuras.

El código, el notebook y los archivos necesarios para reproducir los resultados se encuentran en el repositorio de GitHub.

Repositorio de GitHub: <https://github.com/GiosueFN/Proyecto-2-IMT2230.git>